

Oro kokybės būsenos atkūrimas

CO koncentracijos įvertinimas esant trūkstamiems ir triukšmingiems jautiklių duomenims

Dominykas Kublickas

Grupė EKSfm-26

2026-2027 mokslo metai · 2026 m. rugsėjo 22 d.

Galutinio sprendimo santrauka

Įgyvendintas atkuriamas Python eksperimentas su UCI Air Quality duomenimis. Palyginti du paprasti atskaitos metodai, atsitiktinio miško regresija (RF) ir atraminių vektorių regresija (SVR). Vertinimui slepiami ištisi laiko intervalai; mokymo, validavimo ir testo laikotarpiai nesumaišomi.

A scenarijus · 24 val. spragos	MAE, mg/m ³	Ekstremumų recall
Valandos vidurkis	0,910	0,000
RF	0,391	0,706
SVR	0,547	0,646

Pagrindinė išvada. RF teste sumažino MAE 57,1 % prieš validavime pasirinktą atskaitos metodą. Tačiau vykdymui pagal iš anksto nustatytą validavimo taisyklę buvo parinktas SVR. Testo rezultatas šio pasirinkimo atgaline data nekeičia.

Dokumente pateikiama užduotis, sprendimo metodika, eksperimentiniai rezultatai, klaidų analizė, ribos ir atkuriamumo įrodymai. Programos šaltinio kodas į PDF neįtrauktas. Originalios individualios užduoties lietuviškas tekstas pateiktas A priede.

Uždavinys ir sprendimo paskirtis

Individualioje užduotyje reikia įvertinti teršalo koncentraciją, kai miesto jutiklių dalis matavimų trūksta arba yra triukšmingi. Pasirinktas CO atkūrimas mg/m^3 . Turimas UCI rinkinys atspindi vieną Italijos matavimo vietą, todėl miesto erdvinis tinklas neimituojamas.

Techninė užduotis

Kiekvienos valandos pabaigoje iš tuo metu prieinamų jutiklių ir meteorologijos reikšmių bei jų praeities įvertinti tos pačios valandos CO. Tai būsenos atkūrimas, o ne kitos valandos prognozė. Mokymui reikalingas patikimas CO etalonas; naudojant išminktą modelį CO įvestyje nereikalingas.

Sutarties dalis	Aprašymas
Įvestis	Date, Time; penki PT08 kanalai; T, RH ir AH. Vėlinimai 1, 3 ir 24 val.
Tikslas	CO(GT), mg/m^3 . Nė vienas GT stulpelis ar CO vėlinimas neįtraukiamas į modelio įvestį.
Išvestis	Laikas, <code>co_hat_mg_m3</code> , metodo šaltinis, kokybės žyma, modelio versija ir neigiamo įverčio apribojimo žyma.
Naudojimo vertė	Nenutrūkstamos stebėsenos istorijos papildymas ir laikotarpių jutiklių patikrai atranka.
Klaidos kaina	Nuvertintas pikas gali paslėpti taršos epizodą; pervertinimas gali sukelti nereikalingą patikrą.

Privalomi galutinio darbo elementai

Igyvendinti duomenų paruošimą, abu baseline ir bent du intelektualiuosius metodus; palyginti juos vienodomis sąlygomis; hiperparametrus nenaudoti testo; atlikti abliaciją ir atsparumo bandymą; pateikti lenteles, grafikus, klaidų pavyzdžius, paleidimo instrukciją ir AI auditą. Visi šie elementai pateikti programos pakete ir šiame dokumente.

Ryšys su koliokviumo planu

Išlaikyti 68 požymiai, 60/20/20 chronologija, 24 val. pradžios atmetimas, 6/24/72 val. spragos, sėklos 17/42/101, 18 RF ir 18 SVR konfigūracijų bei numatyti gedimų ir dreifo scenarijai. Pradinis RF pasirinkimas traktuotas kaip hipotezė, kurią turi patikrinti eksperimentas.

Gyvas gynimas, dėstytojo pateikto nematyto bandymo atlikimas ir savarankiškas nedidelis pakeitimas yra atskira vertinimo dalis. Šis dokumentas nepatvirtina, kad gynimas jau įvyko.

Duomenys ir jų paruošimas

Naudotas oficialus UCI Air Quality CSV [1]. Pradinis failas turėjo 9 471 eilutę; pašalinus tuščias liko 9 357 valandiniai įrašai. Faktinis laikotarpis: 2004-03-10 18:00 - 2005-04-04 14:00. Dublikatų ir įterptinų praleistų valandų šiame faile neaptikta. Datų ribos nustatytos iš CSV, o ne rinkinio aprašo.

Duomenys	Trūksta valandų	Dalis
CO(GT)	1683	17,99 %
Kiekvienas iš 8 įvesties kanalų	366	3,91 %

CSV skaitomas su kabliataškiu ir dešimtainiu kableliu. Kodas -200 keičiamas į NaN. Laikas rikiuojamas ir tikrinamas; vienodi dublikatai sutraukiami, prieštarą konkrečiam kanalo reikšmė tampa neprieinama. Dideli CO vien dėl dydžio nešalinami. Laiko juosta ir vasaros laiko pataisos nespėjamos.

Faktinės duomenų dalys

Dalis	Pradžia / pabaiga	Visos val.	Žinomi CO po 24 val.
Mokymas	2004-03-10 18:00 / 2004-10-30 15:00	5614	4153
Validavimas	2004-10-30 16:00 / 2005-01-16 14:00	1871	1694
Testas	2005-01-16 15:00 / 2005-04-04 14:00	1872	1757

Ribos nustatomos pagal visas valandas, dar prieš nežinomo CO filtravimą. Kiekvienos dalies pirmos 24 valandos neįtraukiamos į mokymą ar vertinimą. Medianų, skalių ir ekstremumo slenksčio mokymui naudojamos tik 4 153 mokymo eilutės su žinomu CO. Po validavimo modeliai nepermokomi.

Požymiai ir apsauga nuo nutekėjimo

Požymiai	Kiekis	Taisyklė
Dabartiniai matavimai	8	PT08.S1-S5, T, RH, AH
Istoriniai matavimai	24	Kiekvienas kanalas ties t-1, t-3 ir t-24 pagal laiko žymą
Trūkumo indikatoriai	32	Skaičiuojami po slėpimo ir prieš medianinį užpildymą
Laiko kodavimas	4	Valandos sin/cos ir savaitės dienos sin/cos

Paslėptas jutiklis pašalinamas prieš formuojant vėlinimus. Naudojamos tik mokymo medianos; visiškai tuščiam požymiui taikomas 0 ir išsaugoma trūkumo kaukė. Tikslinis CO neužpildomas nei mokymui, nei vertinimui.

Metodai ir matematinės taisyklės

Atskaitos metodai

Paskutinė reikšmė. $\hat{y}(t) = y(\tau)$, kur τ yra paskutinis griežtai ankstesnis laikas su prieinamu CO. Per paslėptą bloką būseną neatnaujinama paslėptais etalonais ar modelio išvestimis. Jei ankstesnio etalono nėra, naudojamas valandos vidurkis.

Paros valandos vidurkis. $\hat{y}(t)$ = vidurkis mokymo CO reikšmių, priklausančių tai pačiai paros valandai. Kai valandos mokymo pavyzdžių nėra, naudojamas bendras mokymo CO vidurkis. Abu metodai įgyvendinti baselines.py.

Atsitiktinio miško regresija

Medžio mazgas tikrina $x_j \leq \theta$. Pasiekto lapo įvertis $T_b(x)$ yra jo mokymo CO vidurkis su bootstrap pasikartojimais. Miško prognozė:

$$\hat{y}(x) = \max[0, (1/B) \sum_{b=1 \dots B} T_b(x)].$$

Čia $B = 300$ medžių; x yra 68 paruoštų požymių vektorius; j ir θ - mokymo metu parinktas požymis ir skaidymo slenkstis. models.py funkcija create_model nustato bootstrap ir squared_error kriterijų; predict riboja išvestį ties 0; verify_forest_formula palygina atskirų medžių vidurkį su bibliotekos rezultatu.

Realaus modelio formulės patikra: visų 300 medžių vidurkis ir bibliotekos įvertis pirmajam tikrinamam pavyzdžiui yra 4,720175 mg/m³. Didžiausias skirtumas penkiems pavyzdžiams 8.88e-16; tai slankiojo kablelio apvalinimo lygis.

SVR su RBF branduoliu

SVR įvertį sudaro svertinė branduolių kombinacija $f(x) = \sum(\alpha_i - \alpha_i^*) K(x_i, x) + b$; RBF branduolys $K = \exp(-\gamma \|x_i - x\|^2)$. C reguliuoja klaidų kainą, ϵ - nejautrumo intervalą, γ - branduolio mastelį. Prognozė taip pat apribojama ties 0.

Tik 32 matavimų požymiai standartizuojami $z = (u - \mu)/s$; μ ir s išmokstami mokymo dalyje po medianinio užpildymo. Jei $s = 0$, naudojamas 1. Trūkumo kaukės ir sin/cos nestandartizuojami. Tikslinio CO skalė nekeičiama, todėl ϵ vienetai yra mg/m³.

Kodėl šie metodai

RF gali mokytis netiesinių jutiklių sąveikų be mastelio standartizacijos. SVR suteikia kitokią tolydžios netiesinės regresijos alternatyvą. Abu skiriasi nuo jutiklių nenaudojančių baseline. Metodų pasirinkimo literatūrinis pagrindimas pateiktas koliokviumo plane [2]; jų tinkamumas šiam CO uždaviniui vertinamas toliau pateiktu eksperimentu, o ne kitų tyrimų skaičiais.

Eksperimento protokolas ir metrikos

Kiekvienoje vertinimo dalyje po pirmų 24 valandų generuojami nesikertantys 6, 24 arba 72 val. blokai, uždengiantys apie 20 % valandų (paklaida iki vieno bloko). Pradžios parenkamos nepriklausomai nuo CO prieinamumo; naudojamos sėklos 17, 42 ir 101. Vertinamos tik paslėptos valandos su iš pradžių žinomu CO. Visų metodų kaukės sutampa.

Scenarijus	Keitimas
A	Slepiamas tik CO; natūralus jutiklių trūkumas lieka.
B_S1 / B_all	Tuose pačiuose blokuose slepiamas S1 arba visi penki PT08 kanalai.
Triukšmas	S1 pridedamas $N(0, (0,1s)^2)$, s - mokymo kanalo standartinis nuokrypis.
Dreifas	S1 pridedamas tiesinis poslinkis nuo 0 iki 0,5s per testo laikotarpį.
Sisteminis trūkumas	24 val. blokai nuo 7 val.; atskirai - blokai su tikru $CO \geq q_{95}$. Pastarieji yra retrospektyvus streso testas.

Metrikos

MAE = vidurkis $|\hat{y} - y|$ visoms tinkamoms paslėptoms valandoms. **Blokų MAE** = atskirų netuščių blokų MAE vidurkis; blokai sveriami vienodai. Abiejų vienetai mg/m^3 . Papildomai išsaugomas RMSE.

Recall = $TP/(TP + FN)$, **precision** = $TP/(TP + FP)$. Ekstremumas apibrėžtas mokymo CO 95-uoju procentiliu $q = 4,6 mg/m^3$. Tai statistinė, ne sveikatos ar teisinė riba. Kai vardiklis 0, rodiklis neapibrėžtas (lentelėse n/a). Skaičiuojamos ir ekstremumų MAE bei vidutinė ženklinė paklaida $\hat{y} - y$.

Iš anksto nustatyta H1

RF A scenarijaus 24 val. MAE turi būti bent 10 % mažesnė už validavime geresnio baseline, o recall neturi sumažėti daugiau kaip 0,05. Kriterijai yra projekto prielaidos. Jei baseline MAE lygi nuliui arba recall neapibrėžtas, H1 neįvertinama.

Neapibrėžtumas ir kaukių priklausomybė

Kiekvienai kaukei atskirai 1 000 kartų poriniu būdu perrenkami ištisi 24 val. blokai. Skaičiuojamas RF ir baseline MAE skirtumo 95 % intervalas. Persidengiančios kaukės nelaikomos trimis nepriklausomais duomenų rinkiniais; gretimų blokų laikinė priklausomybė riboja intervalų interpretaciją.

Atranka ir pagrindiniai rezultatai

Metodas	Hiperparametrų paieška
RF · 18 versijų	B = 300; max_depth = 8, 16 arba None; min_samples_leaf = 2, 5 arba 10; max_features = 0,7 arba 1,0.
SVR · 18 versijų	RBF; C = 1, 10 arba 100; ϵ = 0,05 arba 0,20; γ = scale, 0,01 arba 0,1.

Kiekviena konfigūracija mokyta vieną kartą su modelio sėkla 42 ir validuota trimis kaukėmis. Minimizuojamas A/24 val. MAE vidurkis. Kai skirtumas nuo mažiausios MAE neviršija 2 %, pirmenybė teikiama didesniai recall, vėliau mažesniai mokymo ir prognozavimo laikui.

Atrinkta versija	Valid. MAE	Valid. recall	Parametrai
RF	0,514	0,597	300; gylis None; lapas 2; požymiai 0,7
SVR	0,517	0,629	C = 10; ϵ = 0,05; γ = 0,01

Validavimo MAE skiriasi tik apie 0,62 %, todėl pagal recall parinktas SVR. Baseline atrankoje laimėjo valandos vidurkis (MAE 1,229; paskutinės reikšmės 1,787). Sprendimas išsaugotas prieš testą; po to mokymas neatnaujintas.

Galutinis testas · A scenarijus · 24 val.


Metodas	MAE	Blokų MAE	Recall	Precision
Paskutinė reikšmė	1,267	1,251	0,363	0,175
Valandos vidurkis	0,910	0,921	0,000	n/a
RF	0,391	0,415	0,706	0,922
SVR	0,547	0,582	0,646	0,972

H1 tenkinama: RF MAE sumažėjimas 57,07 %, recall skirtumas +0,706. SVR MAE sumažėjimas prieš tą patį baseline yra 39,9 %. Teste RF laimėjo prieš SVR, tačiau tai nesuteikia teisės pakeisti jau užfiksuotos atrankos.

Kaukės sėkla	Vertintos val.	Blokai	TP	FN	FP
17	346	15	10	15	1
42	333	15	16	4	1
101	353	15	11	1	1


Lentelių rodikliai yra vienodai sverti trijų kaukių vidurkiai, ne vienas iš sujungtų TP/FN/FP gautas santykis. Vienodas slėpimas ir tos pačios žinomų etalonų valandos leidžia sąžiningai palyginti metodus.

Spragos trukmės ir laiko poveikis



1 pav. A scenarijaus MAE ir ekstremumų recall pagal spragos trukmę. Kiekvienas taškas - trijų kaukių vidurkis.


Paskutinės reikšmės klaida didėja ilgėjant spragai, nes intervale neatsinaujina etalonas. RF ir SVR naudojami tuo pat metu veikiančių kanalų informacija; jų klaida šiuose bandymuose mažesnė. Skirtingų ilgių kaukės dengia ne visai tas pačias valandas, todėl skirtumo negalima priskirti vien trukmei.



2 pav. A/24 val. MAE pagal mėnesį. Pirmiausia skaičiuojama kiekvienos kaukės mėnesio MAE, tuomet jų vidurkis.

Klaidos nėra pastovios laike. Tai suderinama su sąlygų ir jutiklių ryšio kaita, tačiau vien iš šio grafiko jutiklio dreifo priežasties nustatyti negalima. Sausio ir balandžio mėnesiai teste nepilni, todėl mėnesinių stulpelių imtys ir sąlygos skiriasi. Klaidų pagal mėnesį CSV išsaugotas rezultatų pakete.

Atsparumas gedimams ir dreifui



3 pav. Metodų MAE skirtinguose scenarijuose su 24 val. spragomis.

Scenarijus	RF MAE	SVR MAE	Val. vid. MAE	RF recall	SVR recall
Tik CO spragos	0,391	0,547	0,910	0,706	0,646
S1 gedimas	0,489	0,730	0,910	0,218	0,231
Visų PT08 gedimas	1,152	1,308	0,910	0,000	0,000
Triukšmas	0,392	0,547	0,910	0,689	0,662
Dreifas	0,405	0,613	0,910	0,706	0,689
Nuo 7 val.	0,394	0,549	0,889	0,725	0,633
Pikų blokai	0,375	0,395	0,930	0,662	0,657

Aiški veikimo riba. Kai neveikia visi PT08 kanalai, abu intelektualieji metodai pralaimi valandos vidurkiui pagal MAE, o jų ekstremumų recall lygus nuliui. Vieno S1 gedimas taip pat smarkiai mažina ekstremumų aptikimą. Maža bendroji klaida nereiškia, kad patikimai aptinkami reti pikai.

Nedidelis nustatytas triukšmas RF MAE pakeitė menkai; sintetinis dreifas SVR pablogino labiau. Tai galioja tik čia pasirinktam kanalui, triukšmo masteliui ir poslinkio formai. Pikų blokų atranka naudoja tikrą CO, todėl šis scenarijus netinka realaus laiko blokų parinkimui.

Abliacijos ir modelio jautrumas

RF permokytas su tais pačiais pasirinktais hiperparametrais: be visų 24 istorinių matavimų ir jų kaukių (20 požymių), o atskirai be visų 32 trūkumo kaukių (36 požymiai). Tai leidžia tikrinti, ar papildomas požymių sudėtingumas šiame laikotarpyje pasiteisina.

Scenarijus	Versija	MAE, mg/m ³	Recall
A	Pilnas RF	0,391	0,706
A	RF be istorijos	0,376	0,706
A	RF be kaukių	0,391	0,689
B_S1	Pilnas RF	0,489	0,218
B_S1	RF be istorijos	0,467	0,279
B_S1	RF be kaukių	0,478	0,296
B_all	Pilnas RF	1,152	0,000
B_all	RF be istorijos	0,924	0,000
B_all	RF be kaukių	1,135	0,000


A scenarijuje istorijos pašalinimas sumažino MAE nuo 0,391 iki 0,376 mg/m³. Taigi šiame teste daugiau istorinių požymių nesuteikė pranašumo. Tai papildoma analizė: jos pagrindu pagrindinis modelis po testo nekeičiamas. Trūkumo kaukių pašalinimo poveikis priklauso nuo gedimo scenarijaus.

Atsitiktinė modelio sėkla ir ekstremumų svėrimas

Versija · A/24 val.	MAE	Recall	Precision
RF	0,391	0,706	0,922
RF_seed17	0,389	0,689	0,921
RF_seed101	0,390	0,706	0,922
SVR	0,547	0,646	0,972
SVR_W	0,541	0,750	0,887

RF sėklų 17, 42 ir 101 rezultatai panašūs; geriausia sėkla nebuvo atrenkama. SVR_W mokymo ekstremumams taiko svorį 3, kitiems 1, išlaikydama bazinės SVR parametrus. Recall padidėjo iki 0,750, tačiau precision sumažėjo iki 0,887. Tai parodo kompromisą tarp daugiau aptiktų pikų ir klaidingų signalų.

Didžiausios klaidos ir nepastebėti pikai



4 pav. Didžiausios RF blokų MAE intervalas A/24 val. bandyme; slėpimo sėkla 17.

Sėkla	Vertintų laikų pradžia	n	MAE	Riboto pagrįstumo dalis
17	2005-02-10 20:00	24	2,450	100 %
101	2005-01-21 13:00	24	1,767	0 %
42	2005-01-22 20:00	5	1,552	0 %
42	2005-03-12 08:00	19	1,049	0 %
17	2005-02-08 19:00	23	0,959	100 %

Pirmame intervale tikras CO pikas siekė 8,4 mg/m³, o didžiausias RF įvertis - tik 2,197 mg/m³; visos vertintos valandos turėjo riboto pagrįstumo žymą. Tai rodo, kad bendras geras tikslumas neapsaugo nuo didelio konkretaus epizodo nuvertinimo. Kitų intervalų 0 % įspėjimų taip pat negarantuoja mažos klaidos: min-max taisyklė aptinka tik dalį problemų.

Kai bloke yra natūraliai nežinomų etalonų, vertintų valandų skaičius mažesnis nei 24. Lentelės pradžia yra pirmas vertintas laikas, nebūtinai paslėpto bloko pradžia. Visų penkių intervalų pradžios, pabaigos, pikinės reikšmės ir klaidos išsaugotos CSV.

Metodas	Ekstremumų MAE	Vidutinė paklaida $\hat{y} - y$
Paskutinė reikšmė	1,790	-1,604
Valandos vidurkis	2,805	-2,805
RF	1,251	-1,048
SVR	1,179	-1,002

Visų pagrindinių metodų ekstremumų ženklinė paklaida neigiama: pikai vidutiniškai nuvertinami. Visų nepastebėtų ekstremalių epizodų sąrašas pateiktas `missed_extreme_episodes.csv`; `baseline_wins.csv` pateikia valandas, kai valandos vidurkis tikslesnis už RF. Šios išimtys nepaslepamos bendru vidurkiu.

Patikimumas ir praktinės ribos

Porinis blokų bootstrap

Kaukės sėkla	Blokų sk.	RF - baseline MAE	95 % intervalo ribos
17	15	-0,522	-0,774 ... -0,304
42	15	-0,567	-0,705 ... -0,440
101	15	-0,470	-0,617 ... -0,292

Visi trys apytiksliai intervalai yra žemiau nulio, todėl kiekvienos kaukės bandyme RF taškinės klaidos pranašumas prieš valandos vidurkį nėra paaiškinamas vien šiuo blokų perrinkimu. Tačiau laikinė priklausomybė ir kaukių persidengimas neleidžia šių intervalų laikyti nepriklausomais patvirtinimais ar garantija kitam laikotarpiui.

Kodėl modeliai laimėjo ir kada nelaimėjo

Esant prieinamiems kanalams, modeliai gali naudoti jutiklių ir meteorologijos netiesinius ryšius. Paskutinė CO reikšmė bloko metu nekinta, o valandos vidurkis neatsižvelgia į konkrečios dienos epizodą. Visų PT08 gedimas pašalina pagrindinę informaciją, todėl intelektualieji metodai tampa blogesni už paprastą baseline. RF lapų vidurkinimas ir retos mokymo ekstremumų imtys gali prisidėti prie pikų mažinimo; eksperimentas neįrodo vienos priežasties.

Naudojimo žymos ir operatoriaus veiksmai

Žyma	Sąlyga ir veiksmas
atkurtas	Nėra aptikto įvesties trūkumo ar PT08 min-max perspėjimo. Įvertis vis tiek nėra etaloninis matavimas.
trūksta dalies įvesčių	Trūksta bent vienos matavimo ar istorijos reikšmės; ji užpildoma mokymo mediana. Peržiūrėti ilgas spragas.
ribotas pagrįstumas	Nėra nė vieno dabartinio PT08 arba bent vienas kanalas už mokymo min-max ribų. Reikalinga operatoriaus patikra.

A/24 val. bandyme bent dalies įvesčių ar ribų įspėjimą turėjo apie 42,4 % vertintų kaukės-valandos porų. Ši žyma yra euristika, ne pasikliautinasis intervalas. Neigiamų prognozių apribojimų dalis registruojama metrikose.

Išvadų taikymo ribos

Viena sena matavimo vieta neleidžia išvadų tiesiogiai perkelti į dabartinį miestą. Žinomų etalonų slėpimas neparodo tikrų natūralių spragų klaidos. Sintetinis vieno kanalo dreifas neatkuria viso jutiklių senėjimo. Prieš diegimą reikalingas vietinis kalibravimas, naujas laike atskirtas testas ir etaloninė priežiūra. Finansinė grąža be diegimo sąnaudų neskaičiuojama.

Paleidimas ir atkuriamumo įrodymai

Programa pateikta aplanke Air Quality. Windows paleidimo meniu Air_Quality.cmd leidžia atverti ataskaitą, kartoti eksperimentą, prognozuoti CSV ir paleisti testus. Python 3.12 aplinka ir konkrečios bibliotekų versijos aprašytos requirements-lock.txt.

Pagrindinio eksperimento komanda

python run_experiment.py --config config.yaml

Duomenys atsisiunčiami iš oficialaus UCI archyvo, jei vietinio CSV nėra. Jau užpildytas rezultatų aplankas neperrašomas: kuriamas aplankas su laiko žyma. Interneto reikia tik pirmam duomenų ar bibliotekų atsisiuntimui.

Naujo CSV įvertinimas

python predict.py --input destytojo.csv --output predictions/rezultatas.csv

UCI formato failui būtini Date, Time, penki PT08, T, RH, AH stulpeliai; CO(GT) neprivalomas. Pirmos 24 valandos gali turėti trūkstamą istoriją. Ankstesnę 24 val. istoriją galima pridėti į failo pradžią. Prognozavimo komanda modelio nepermoko.

Įrodymas	Failas arba rezultatas
Duomenų kilmė ir laiko ribos	data_audit.json, split.json
Atranka prieš testą	selection.json, validation_metrics.csv
Vertinimo atkuriamumas	masks.csv.gz, predictions.csv.gz, metrics.csv
Formulė ir preprocessing	formula_check.json, preprocessing.json
Automatiniai testai	12 protokolo testų praėjo; tests.txt
Nepriklausoma skaitinė patikra	363 metrikų eilutės, 125 176 prognozės, sutampančios kaukės ir 48 eilučių prognozė be CO; verification.json

Visas mokymas ir vertinimas truko apie 5,0 min. iki ataskaitos braižymo. Naudota iki 4 gijų, 12 loginių CPU kompiuteryje su 31,8 GB RAM. Taikytos 120 s vieno mokymo ir 2 val. bendro eksperimento ribos; nebaigtų bandymų nėra. 8 GB atminties riba stebi mokymo procesą ir jo vaikus, ne visą sistemą.

Duomenų SHA-256: 13277ae5d8581e80b7be09d47c7d3d06fe9b8e957078f2cf6e859f955e62f996

Programos kodo repozitorija: github.com/MrWildBerry/air-quality-eksfm26. Saugykla privati; vertinimui skirta prieiga vartotojui serackis. Repozitorijoje pateiktas šaltinio kodas, testai, paleidimo instrukcijos ir ši PDF dokumentacija. Duomenis programa atsisiunčia, o modelius ir rezultatų failus atkuria paleidus pagrindinį eksperimentą.

AI naudojimas ir galutinės išvados

Codex naudotas programos, testų ir dokumentacijos juodraščiams bei eksperimentų vykdymui. Pagrindinė vartotojo užklausa: pagal pateiktą koliokviumo planą ir galutinio darbo kriterijus sukurti programą; vėliau - parengti PDF dokumentaciją ir kodą pateikimui repozitorijoje.

AI klaida arba nepatikrinta prielaida	Patikra ir sprendimas
Biblioteka scikit-learn jau įdiegta	Importas grąžino <code>ModuleNotFoundError</code> . Sukurta virtuali aplinka, įdiegtos ir užfiksuotos versijos.
Windows išvestis palaikys dokumentų simbolius	Ištraukimas nutrūko su <code>UnicodeEncodeError</code> . Naudota UTF-8 ir abu dokumentai perskaityti iš naujo.
RF yra garantuotai geriausias	36 konfigūracijų validavimas parinko SVR pagal 2 % ir recall taisyklę; teste RF gavo mažesnę MAE. Pradinė hipotezė atskirta nuo atrankos.
Slėpimas negali nutekėti per vėlinimus	Specialūs testai tikrina paslėptą S1 ties t+1 ir t+24, CO neįtraukimą ir ateities įtakos ankstesnei prognozei nebuvimą.

Priimtas chronologinis protokolas ir realių rezultatų generavimas iš failų. Atmesti atsitiktinis train/test skaidymas, ateities interpolacija ir paslėpto CO naudojimas modelyje. Tikrintas oficialus UCI duomenų šaltinis. Koliokviumo straipsnių DOI šiame programavimo ir dokumentavimo etape iš naujo netikrinti; nauji jų rezultatų teiginiai nekuriami.

Galutinės išvados

1. Sukurtas veikiantis ir pakartojamas CO atkūrimo sprendimas su abiem baseline, RF ir SVR, atskiriant mokymą, atranką ir testą.
2. A/24 val. teste RF MAE 0,391 mg/m³ ir recall 0,706; H1 kriterijai tenkinami. Validavime parinktas SVR teste pasiekė 0,547 mg/m³ MAE. Atrankos ir galutinio laimėtojo skirtumas dokumentuotas.
3. Visų PT08 gedimas panaikino abiejų intelektualiujų metodų pranašumą ir ekstremumų aptikimą. Todėl kokybės perspėjimai ir etaloninė priežiūra yra būtini praktiniam naudojimui.
4. Abliacija nepatvirtino, kad istorija visada naudinga; SVR ekstremumų svėrimas pagerino recall, bet sumažino precision. Papildomi bandymai nepaversti atranka pagal jau matytą testą.

Naudoti dokumentai ir šaltiniai

[1] Vito, S. (2008). Air Quality. UCI Machine Learning Repository. DOI: [10.24432/C59K5F](https://doi.org/10.24432/C59K5F). Rinkinio puslapis: archive.ics.uci.edu/dataset/360/air+quality.

[2] Kublickas, D. (2026). Koliokviumo įgyvendinimo planas. Koliokviumas_D_Kublickas_EKSfm26.pdf, 2026-09-17. [3] Individuali 2026-2027 m. užduotis, EKSfm-26_Dominykas_Kublickas.docx. [4] Šio projekto išsaugoti prognozių, metrikų, kaukių ir vykdymo audito failai.

Originali individuali užduotis

Toliau perkelta vartotojo pateikto užduoties dokumento lietuviška dalis. Angliškas to paties turinio vertimas nekartojamas.

Intelektualiosios sistemos

Individuali 2026-2027 m. užduotis

Oro kokybės būsenos atkūrimas

Miesto jutiklių tinkle dalis matavimų trūksta arba yra triukšmingi. Reikia įvertinti teršalų koncentraciją.

Duomenys ir sprendimo tikslas

Siūlomas viešas duomenų rinkinys: UCI Air Quality, <https://archive.ics.uci.edu/dataset/360/air+quality>

Prognozuojamas rezultatas: Pasirinkto teršalo koncentracija arba oro kokybės klasė.

Privalomas paprastas atskaitos metodas: Paskutinės reikšmės ir paros valandos vidurkio prognozė.

Svarstylini intelektualieji metodai: SVR, MLP, SOM anomalijoms, fuzzy oro kokybės indeksas. Galima pasirinkti kitus metodus, jei pasirinkimas pagrįstas literatūra ir eksperimentu.

Pagrindinės vertinimo kryptys: MAE, trūkstamų intervalų klaida ir ekstremumų recall.

Duomenų skaidymo reikalavimas: Dirbtinai paslėpti ištisus laiko intervalus, ne atsitiktines pavienes eilutes.

Svarbiausias probleminis aspektas: Jutiklių dreifas ir sistemingai trūkstami duomenys.

Kolokviumo dalis

Kolokviumui reikia parengti įgyvendinimo planą. Kodo ir galutinių rezultatų dar nereikalaujama, tačiau planas turi būti pakankamai konkretus, kad pagal jį kitas programuotojas galėtų pradėti darbą.

Suformuluoti problemą, techninį uždavinį ir praktinę sprendimo vertę. Įvardyti neaiškumus, apribojimus ir klaidų kainą.

Išskaidyti sprendimą į duomenų gavimo, paruošimo, modelio mokymo, vertinimo ir naudojimo etapus. Aiškiai aprašyti įvestį ir išvestį.

Pateikti 2–4 galimus intelektualiuosius metodus ir paprastą baseline. Kiekvieno metodo tinkamumą pagrįsti patikrintais pirminiais šaltiniais; pateikti DOI arba stabilias nuorodas.

Pasirinkti pagrindinį metodą ir suformuluoti patikrinamą hipotezę, kuo bei kokiomis sąlygomis jis turėtų pranokti baseline.

Pateikti pagrindines pasirinkto modelio formules arba taisykles, paaiškinti kintamuosius ir susieti jas su planuojamais programos moduliais.

Iš anksto aprašyti duomenų skaidymą, preprocessing, metrikas, abliaciją, klaidų analizę, skaičiavimo biudžetą ir didžiausias grėsmes išvadų galiojimui.

Pateikti AI naudojimo planą: kam AI bus naudojamas, kaip bus tikrinamos citatos, formulės, kodas ir rezultatai.

Galutinio egzamino reikalavimai

Galutinio egzamino dalis

Galutiniam egzaminui reikia pateikti veikiantį ir atkuriamą sprendimą bei įrodymus, leidžiančius įvertinti jo ribas.

Įgyvendinti duomenų paruošimo grandinę, baseline ir bent du intelektualiuosius metodus. Bent vienam modeliui parodyti formulės ar taisyklės ryšį su konkrečia kodo vieta.

Palyginti metodus tuo pačiu duomenų skaidymu ir tomis pačiomis metrikomis. Hiperparametrų parinkimui nenaudoti galutinio testo.

Atlikti bent vieną abliaciją arba požymių jautrumo bandymą ir bent vieną atsparumo bandymą: triukšmui, trūkstamiems duomenims, laiko ar grupės poslinkiui.

Pateikti rezultatų lentelę, tinkamą grafiką, klaidų pavyzdžius ir paaiškinti, kodėl pasirinktas metodas laimėjo arba nelaimėjo. Neigiamas rezultatas priimtinas, jei eksperimentas korektiškas.

Pateikti paleidimo instrukciją, priklausomybių sąrašą, fiksuotas atsitiktines sėklas ir vieną komandą pagrindiniam eksperimentui pakartoti. Duomenų failų kopijų teikti nereikia, jei yra atsisieniavimo instrukcija.

Pateikti AI naudojimo žurnalą: svarbiausios užklauskos, priimti ir atmesti pasiūlymai, bent dvi aptiktos AI klaidos arba nepatikrintos prielaidos ir jų patikros būdas.

Gyvo gynimo metu paaiškinti pasirinktą formulę bei kodą, paleisti dėstytojo pateiktą nematytą bandymą ir atlikti nedidelį modelio, metrikos ar duomenų apdorojimo pakeitimą.

Kolokviumo vertinimas

Kolokviumas vertinamas 10 balų skale. Surinkti balai tiesiogiai sudaro 10 % galutinio dalyko pažymio. Kolokviume vertinamas įgyvendinimo planas; veikiantis kodas ir galutiniai eksperimentų rezultatai dar nereikalingi.

Galutinio egzamino vertinimas

Galutinio egzamino rezultatas vertinamas 90 balų skale ir sudaro 90 % galutinio dalyko pažymio.

Galutinis dalyko rezultatas (%) = kolokviumo balai + egzamino balai. Didžiausias rezultatas: $10 + 90 = 100$ balų.

AI įrankius naudoti leidžiama. AI sugeneruotas tekstas, citata ar rezultatas savaime nėra įrodymas. Studentas atsako už duomenų kilmę, kodo veikimą, šaltinių tikrumą ir pateiktas išvadas.

Užduoties vertinimo kriterijai

Studentas	Dominykas Kublickas
Grupė	EKSfm-26
Vertinama kolokviumo dalis	Balai
Problemos formulavimas, apribojimai ir klaidų kaina	2
Alternatyvūs metodai, baseline ir literatūros pagrindimas	2
Įvestis, išvestis, formulės arba taisyklės ir būsimo kodo struktūra	2
Duomenų skaidymo, metrių, eksperimentų ir rizikų planas	3
AI naudojimo ir pateiktos informacijos tikrinimo planas	1
Vertinama galutinio egzamino dalis	Balai
Baseline, duomenų grandinė ir atkuriamumas	10
Bent dviejų intelektualųjų metodų įgyvendinimas	20
Eksperimento korektiškumas ir vienodos palyginimo sąlygos	20
Rezultatai, abliacija, atsparumo bandymas ir klaidų analizė	15
Sprendimo ribos, rizikos ir praktinis tinkamumas	10
AI naudojimo auditas	5
Gyvas gynimas, nematytas testas ir nedidelis pakeitimas	10