

Galutinio egzamino sprendimo dokumentacija

Oro kokybės būsenos atkūrimas kai CO etalonas neprieinamas

Dominykas Kublickas | EKSfm-26 | atnaujinta versija

Santrauka

Naudojant UCI Air Quality valandinius duomenis palyginti du paprasti atskaitos metodai, atsitiktinio miško regresija, įprasta atraminių vektorių regresija ir jos svertinė modifikacija. Užrakinta galutinė konfigūracija po validavimo galutiniame etape testuota vieną kartą. Pagrindiniame A/24 val. teste RF turi mažiausią bendrą MAE, o svertinė SVR geriausiai atkuria retas aukštas CO reikšmes pagal ekstremumų MAE ir jautrį.

Pagrindinio A/24 testo rezultatas	MAE	Ekstremumų MAE	Jautris
Paskutinė reikšmė	1,267	1,790	0,363
Paros valandos vidurkis	0,910	2,805	0,000
Atsitiktinio miško regresija	0,395	1,239	0,678
Atraminių vektorių regresija	0,547	1,179	0,646
Svertinė atraminių vektorių regresija	0,535	1,087	0,750

Ką sprendžia programa

Praktinė problema

Oro kokybės stebėsenoje CO etalono reikšmė gali būti neprieinama dėl ryšio, priežiūros ar paties etalono gedimo, nors tuo pat metu gaunami pigesnių PT08 jutiklių ir meteorologiniai matavimai. Šio darbo tikslas - kiekvienos valandos pabaigoje atkurti tos pačios valandos CO koncentraciją, kai CO etalonas trūksta. Sprendimas nėra kitos valandos prognozė: jis negali naudoti vėlesnių valandų duomenų, ateities interpoliacijos ar ankstesnių paslėpto CO reikšmių iš paties spragos intervalo.

Praktinė vertė ir klaidų kaina

Atkurtas įvertis gali papildyti stebėsenos istoriją ir padėti atrinkti laikotarpius etalono arba jutiklių patikrai. Piko nuvertinimas gali neparodyti taršos epizodo, o pervertinimas gali sukelti nereikalingą patikrą. Šiame rinkinyje q95 yra statistinė mokymo duomenų riba, ne sveikatos ar teisinė norma.

Techninis įgyvendinimas

Į modelį patenka penki PT08 kanalai, T, RH, AH ir jų praeities reikšmės; CO etalonas naudojamas tik mokymui ir vėlesniam tikslumo apskaičiavimui. Jei tam tikroje testavimo valandoje CO paslėptas, modelis grąžina ``co_hat_mg_m3`` ir kokybės žymą. Tai leidžia įvertinti atkūrimo kokybę, bet nepatvirtina diegimo kitame mieste ar su nauju jutikliu.

Alternatyvos, pasirinkimas ir modifikacija

Palyginti metodai

Metodas	Vaidmuo ir prielaida
Paskutinė žinoma reikšmė	Naudoja tik paskutinį iki spragos buvusį CO; per spragą neatsinaujina.
Paros valandos vidurkis	Naudoja mokymo CO vidurkį tai pačiai paros valandai; neatsižvelgia į konkretaus momento jutiklius.
RF	Mokosi netiesinių jutiklių ir meteorologijos ryšių.
SVR	RBF branduoliu modeliuoja glotnų netiesinį ryšį.
SVR-W	SVR mokymui retas aukštas CO reikšmės padaro svarbesnes.

Literatūra ir projekto adaptacija

Zhen ir kt. (2025) nagrinėjo retų didelių O3 reikšmių nuvertinimą ir pasiūlė mokymo pavyzdžių svėrimu pagrįstą SVR-W. Tai pagrindžia svėrimo idėjos svarstymą oro taršos regresijoje. Šiame projekte jų algoritmas nėra kopijuojamas: CO ekstremumo riba apibrėžiama mokymo q95, o w ir SVR parametrai parenkami validavimo duomenimis. Todėl rezultatai yra šio CO rinkinio eksperimento, ne straipsnio rezultatų pakartojimas.

Pasirinkimo hipotezė

Prieš testą užrašyta hipotezė: SVR-W turėtų pagerinti ekstremumų MAE ir jautrį prieš SVR, neprastindama bendro MAE daugiau nei 2 %. Atrankos taisyklė ir rezultatas užfiksuoti `selection.json`.

Duomenų grandinė, kaukės ir metrikos

Chronologinis skaidymas

Dalis	Laikotarpis	Valandos	Žinomas CO po pradinio laikotarpio
train	2004-03-10 18:00 - 2004-10-30 15:00	5614	4153
validation	2004-10-30 16:00 - 2005-01-16 14:00	1871	1694
test	2005-01-16 15:00 - 2005-04-04 14:00	1872	1757

Požymiai, medianos, vidurkiai, skalės, q95 ir jutiklių ribos apskaičiuojami tik mokymo dalyje. Validavimui ir testui pirma sukurama maskuota įvestis, po to iš jos sudaromi lag požymiai. Taip išvengiama tikslinio kintamojo ir ateities duomenų nutekėjimo.

Metrikos

MAE matuoja vidutinę absoliučią paklaidą. RMSE dideles klaidas baudžia stipriau. Blokų MAE pirmiausia apskaičiuoja kiekvieno paslėpto intervalo MAE, tada juos sveria vienodai. Ekstremumų MAE yra absoliuti paklaida tik tikram CO $\geq$ q95. Jautris TP/(TP+FN) parodo, kiek tikrų ekstremumų aptikta; preciziškumas TP/(TP+FP) rodo, kiek paskelbtų ekstremumų buvo teisingi. Vidutinė ženklinė paklaida $\hat{y}$ -y nurodo sistemingą pervertinimą arba nuvertinimą.

Svarbi riba

`extreme` scenarijuje blokai retrospektyviai parenkami taip, kad juose būtų tikras ekstremumas. Jis pateikiamas kaip streso testas, o ne kaip realaus laiko atsitiktinės spragos įvertis.

Validavimas ir užrakinta konfigūracija

Pilname validavime patikrintos 18 RF, 18 SVR ir 90 SVR-W konfigūracijų. q95 buvo skaičiuojamas tik iš mokymo CO, o $w \in \{1, 2, 3, 5, 8\}$ tikrintas trimis A/24 val. validavimo kaukėmis. Kiekvienam kandidatui išsaugoti MAE, ekstremumų MAE, jautris, preciziškumas ir vykdymo laikas.

Atrinktas kandidatas	Parametrai	Validavimo MAE	Ekstremumų MAE	Jautris	Preciziškumas
SVR-W, w=5	C=10; epsilon=0,05; gamma=0,01	0,513	1,063	0,666	0,812
SVR	C=10; epsilon=0,05; gamma=0,01	0,517	1,191	0,629	0,856
RF	300 medžių; gylis neribotas; lapas 2	0,510	1,207	0,593	0,882

SVR-W, w=5, parinktas todėl, kad pagerino jautrį ir ekstremumų MAE, o bendras MAE išliko 2 % atrankos tolerancijoje. Vėliau sukurtame `config\_final\_locked.yaml` paliktos tik šios konfigūracijos. Testas neturėjo būti naudojamas šiai atrankai keisti.

Pagrindinis A scenarijus su 24 val. spragomis

Metodas	MAE	RMSE	Blokų MAE	Ekstr. MAE	Jautris	Preciziškumas	Ekstr. paklaida
Paskutinė reikšmė	1,267	1,728	1,251	1,790	0,363	0,175	-1,604
Paros valandos vidurkis	0,910	1,204	0,921	2,805	0,000	neapibrėžta	-2,805
Atsitiktinio miško regresija	0,395	0,710	0,420	1,239	0,678	0,895	-0,945
Atraminų vektorių regresija	0,547	0,810	0,582	1,179	0,646	0,972	-1,002
Svertinė atraminų vektorių regresija	0,535	0,814	0,571	1,087	0,750	0,887	-0,706


Lentelėje pateikti tik testinių A/24 val. prognozių trijų identiškų kaukių vidurkiai. Visi penki metodai vertinti tomis pačiomis paslėptomis valandomis. Paros valandos vidurkis nepaskelbė nė vieno ekstremumo, todėl jo preciziškumas neapibrėžtas.

Rezultatų interpretacija

RF turi mažiausią bendrą MAE (0,395 mg/m³), jo preciziškumas yra 0,895. Įprasta SVR turi didžiausią preciziškumą (0,972). SVR-W turi mažiausią ekstremumų MAE (1,087 mg/m³) ir didžiausią jautrį (0,750), bet mažesnę preciziškumą (0,887). Lyginant su SVR, SVR-W sumažino ekstremumų MAE nuo 1,179 iki 1,087 ir padidino jautrį nuo 0,646 iki 0,750, kartu sumažindama bendrą MAE nuo 0,547 iki 0,535. Tai yra kompromisas tarp retų pikų aptikimo ir papildomų klaidingų signalų, o ne vienareikšmis visų tikslų laimėjimas.

Faktinės ir atkurtos CO reikšmės

Tipinis geras: A, kaukė 101, blokas 14




Automatinės skaitinės išvados

1. Tikros CO maksimumas: 3.00 mg/m³; virš q95=4.60 yra 0/24 val.
2. Mažiausias bloko MAE: SVR = 0.259 mg/m³.
3. RF MAE=0.264; pasirinktas neekstremalus A/24 blokas, artimiausias A/24 blokų RF MAE medianai.

1 pav. Tipinis pagrindinio A scenarijaus 24 val. intervalas: faktinė CO kreivė, visų metodų įverčiai ir geltonai pažymėtas paslėptas intervalas. Po grafiku pateiktos automatiškai apskaičiuotos išvados.


Weighted svr pagerėjimas: A, kaukė 17, blokas 12



2 pav. Pagrindinio A/24 scenarijaus intervalas, kuriame SVR-W bloko MAE mažesnė už SVR. Tikslus absoliutus ir procentinis skirtumas automatiškai apskaičiuotas po grafiku. Tai retrospektyvus klaidų analizės pavyzdys, nenaudotas modelio atrankai.

Kada sprendimas neveikia

3 pav. Didžiausios RF blokų MAE intervalas: RF MAE 2,478 mg/m³, o tikras maksimumas 7,10 mg/m³.



Automatinės skaitinės išvados

1. Tikros CO maksimumas: 8.40 mg/m³; virš q95=4.60 yra 11/24 val.
2. Mažiausias bloko MAE: Paros valandos vidurkis = 2.285 mg/m³.
3. RF/SVR/weighted SVR prognozuoti pikai: 2.21 / 2.00 / 1.99 mg/m³.

4 pav. Intervalas su didžiausiu tikru CO piku 8,40 mg/m³. Pagrindiniai modeliai šio piko nepasiekia, todėl geras bendras MAE negarantuoja patikimo kiekvieno epizodo atkūrimo.

Ribos

Vienos stoties seni duomenys neleidžia teigti, kad sprendimas tiks kitam miestui ar naujam jutikliui. Dirbtinis etalono slėpimas nėra tas pats, kas natūralus gedimas. S1 triukšmas ir dreifas yra sintetiniai. Visiems PT08 kanalams sugedus, intelektualūs modeliai neturi pagrindinių signalų ir jų rezultatai turi būti interpretuojami atsargiai. Kokybės žyma yra praktinė taisyklė, ne pasikliautinis intervalas.

Patikros įrodymai

Duomenų kilmė ir rezultatai

UCI Air Quality CSV SHA-256:

13277ae5d8581e80b7be09d47c7d3d06fe9b8e957078f2cf6e859f955e62f996. Galutinio testo artefaktai saugomi `results\_final\_locked/`: `config\_used.json`, `split.json`, `selection.json`, `masks.csv.gz`, `predictions.csv.gz`, `metrics.csv`, `preprocessing.json`, `training\_audit.json` ir `verification.json`.

Nepriklausoma patikra

`verify\_results.py` patikrino SHA sutapimą, testinių prognozių laiko ribas, kaukių atkūrimą, neneigiamas baigtines prognozes ir MAE bei blokų MAE perskaičiavimą. Vėlesnis auditas perskaičiavo visas 363 metrikų eilutes iš 125 176 prognozių eilučių be neatitikimų. Išsamus dokumentas - `FINAL\_AUDIT.md`.

AI naudojimo ribos

AI padėjo ieškoti šaltinių, kurti kodą, testus, dokumentacijos juodraštį ir atlikti patikras. AI atsakymas nėra įrodymas: studentas atsako už šaltinių tikrumą, eksperimentinių teiginių supratimą ir gyvą gynimą. `AI\_NAUDOJIMO\_ZURNALAS.md` išsaugo svarbiausias užklausas, priimtus ir atmestus sprendimus, pastebėtas klaidas bei jų patikras.

Šaltiniai

Vito (2008), DOI 10.24432/C59K5F. Breiman (2001), DOI 10.1023/A:1010933404324. Cortes ir Vapnik (1995), DOI 10.1007/BF00994018. Zhen ir kt. (2025), Atmospheric Environment 343, 120952, DOI 10.1016/j.atmosenv.2024.120952. Hua ir kt. (2024), PLOS ONE 19(9), e0306303, DOI 10.1371/journal.pone.0306303.