

Atnaujintas koliokviumo planas

Oro kokybės būsenos atkūrimas naudojant jutiklių ir meteorologinius duomenis

Dominykas Kublickas | EKSfm-26 | 2026 m. rugsėjis

Dokumento paskirtis

Šis planas atnaujintas pagal dėstytojo pastabas. Jame atskiriama praktinė problema nuo techninės užduoties, pagrindžiami svarstyti metodai naujesniais šaltiniais, aprašomas patikrinamas eksperimentas ir aiškiai nurodomos rizikos.

Praktinė ir techninė užduotis

Praktinė problema

Oro kokybės stebėsenoje CO etalono reikšmė gali būti neprieinama dėl ryšio, priežiūros ar paties etalono gedimo, nors tuo pat metu gaunami pigesnių PT08 jutiklių ir meteorologiniai matavimai. Šio darbo tikslas - kiekvienos valandos pabaigoje atkurti tos pačios valandos CO koncentraciją, kai CO etalonas trūksta. Sprendimas nėra kitos valandos prognozė: jis negali naudoti vėlesnių valandų duomenų, ateities interpoliacijos ar ankstesnių paslėpto CO reikšmių iš paties spragos intervalo.

Praktinė vertė ir klaidų kaina

Atkurtas įvertis gali papildyti stebėsenos istoriją ir padėti atrinkti laikotarpius etalono arba jutiklių patikrai. Piko nuvertinimas gali neparodyti taršos epizodo, o pervertinimas gali sukelti nereikalingą patikrą. Šiame rinkinyje q95 yra statistinė mokymo duomenų riba, ne sveikatos ar teisinė norma.

Dalis	Aprašymas
Įvertis	Penki PT08 jutikliai, T, RH, AH, jų reikšmės tuo metu ir t-1, t-3, t-24.
Tikslas	CO(GT), mg/m ³ ; mokymui prieinamas etalonas, veikimo metu jis paslėptas.
Išvertis	CO įvertis, metodo pavadinimas, kokybės žyma ir apribojimo ties nulių žyma.
Ribos	Viena sena Italijos stotis; nevertinamas perkėlimas į kitą miestą ar dabartinius jutiklius.

Alternatyvos ir literatūros pagrindas

Atskaitos metodai

Paskutinė žinoma CO reikšmė parodo, kiek galima pasiekti vien iš ankstesnio etalono. Paros valandos vidurkis parodo sezoninį paros ritmą be konkretaus momento jutiklių. Abu metodai sąmoningai paprasti ir naudojami kaip palyginimo atskaitos taškai.

Svarstyti intelektualieji metodai

Metodas	Kodėl svarstomas	Sprendimas
Atsitiktinio miško regresija	Tinka netiesiniams jutiklių ir meteorologijos ryšiams; nenaudoja ateities reikšmių.	Igyvendintas kaip RF.
RBF atraminių vektorių regresija	Sudaro glotnų netiesinį ryšį mažo ir vidutinio dydžio duomenims; įvestys standartizuojamos tik iš mokymo dalies.	Igyvendintas kaip SVR.
Svertinė SVR	Zhen ir kt. (2025) parodė, kad retų aukštų oro teršalo reikšmių nuvertinimą galima mažinti treniruojant SVR su didesniais aukštų taikinių pavyzdžių svoriais.	Igyvendinta CPU režimu kaip SVR-W.
Dvikryptės laiko eilučių imputacijos sistemos	Hua ir kt. (2024) tiria BRITS, MRNN, SAITS ir Transformer tipo imputacijos metodus. Dalis jų naudoja dvikryptį arba viso intervalo kontekstą; jų tiesioginiam taikymui reikėtų patikrinti priežastinę realaus laiko sąlygą.	Palikti tolesniam tyrimui: priežastinė adaptacija būtų sudėtingesnė už pasirinktą CPU realizaciją; jų sąnaudos šiame projekte nematuotos.

Literatūros interpretacija

Zhen ir bendraautorių straipsnis nagrinėja ozoną, kitus duomenis ir jų pačių svėrimo strategiją. Šiame darbe nėra atkuriamas jų konkretus algoritmas. Perimama tik patikrinta idėja: jei didelės teršalo reikšmės retos ir jų nuvertinimas svarbus, mokymo pavyzdžių svėrimas yra pagrįstai svarstyтина SVR modifikacija. CO riba q95 apskaičiuojama tik iš mokymo duomenų, o svoriai parenkami tik validavime.

Skaidymas, požymiai ir nutekėjimo prevencija

Duomenys gaunami iš UCI Air Quality rinkinio. CSV -200 reikšmės keičiamos į trūkstamas reikšmes, laikas sutvarkomas į valandinį tinklėlį, o pradinio failo SHA-256 įrašomas į audito failą. Duomenų skaidymas atliekamas chronologiškai prieš filtruojant žinomus CO.

Dalis	Laikotarpis	Valandos	Žinomas CO po pradinio laikotarpio
train	2004-03-10 18:00 - 2004-10-30 15:00	5614	4153
validation	2004-10-30 16:00 - 2005-01-16 14:00	1871	1694
test	2005-01-16 15:00 - 2005-04-04 14:00	1872	1757

Pirma kuriama paslėpta įvesties versija, tik tada formuojami t-1, t-3 ir t-24 lag požymiai. Todėl paslėpto momento jutiklio reikšmė negali patekti į vėlesnės valandos lagą. CO(GT) ir CO lagai niekada nėra modelio požymiai.

Duomenų paruošimas

Medianų užpildymas, SVR vidurkiai ir skalės fitinami tik mokymo `X`. Trūkumo kaukė išsaugoma prieš medianinį užpildymą. Modelis mokomas tik pirmų 60 % duomenų, hiperparametrai ir svoriai renkami validavime, o testas nenaudojamas atrankai.

Iš anksto patikrinamas eksperimentas

Hipotezė

Svertinė SVR, aukštomis mokymo CO reikšmėms suteikianti didesnę svorį, turėtų sumažinti ekstremumų MAE ir padidinti ekstremumų aptikimo jautrį, palyginti su įprasta SVR, nepadidindama bendro MAE daugiau nei 2 %. Tai yra tikrinama hipotezė, o ne iš anksto priimta išvada.

Validavimo planas

q95 apskaičiuojamas tik iš mokymo CO. Kiekvienam mokymo pavyzdžiui virš q95 suteikiamas w iš {1, 2, 3, 5, 8}; SVR C, epsilon ir gamma taip pat renkami tik validavime. Naudojamos trys A/24 val. kaukės su sėklomis 17, 42 ir 101. Kandidatams išsaugoma MAE, ekstremumų MAE, jautris, preciziškumas ir laikas.

Metrikos aiškiai

MAE yra vidutinė absoliuti paklaida mg/m^3 ; RMSE labiau baudžia dideles klaidas; blokų MAE vienodai sveria kiekvieną paslėptą bloką; ekstremumų MAE skaičiuojama tik tada, kai tikras CO $\geq$ q95; jautris rodo aptiktų tikrų ekstremumų dalį, o preciziškumas - kiek paskelbtų ekstremumų iš tikrųjų buvo ekstremalūs. Vidutinė ženklinė paklaida $\hat{y}-y$ nurodo sistemingą per- arba nuvertinimą.

Rizikos

Dirbtinis žinomų CO slėpimas gali skirtis nuo tikrų gedimų. Vienos stoties rezultato negalima perkelti į kitą vietą. Retrospektyvus `extreme` scenarijus blokams parinkti naudoja testinį CO, todėl jis bus pateikiamas tik kaip streso testas, ne kaip realaus laiko kaukių dažnio įvertis.

Patikros planas

AI naudojamas literatūros paieškai, kodo ir dokumentacijos juodraščiui, bet jo teiginiai tikrinami: išsaugomas duomenų SHA, paleidžiami protokolo testai, perskaičiuojamos metrikos iš prognozių ir atliekamas nepriklausomas leakage auditas. Prieš galutinį testą studentas turi perskaityti atrankos lentelę ir patikrinti, kad pasirinktas kandidatas atitinka išsaugotą modelio artefaktą.

Pirminiai šaltiniai

[1] Vito, S. (2008). Air Quality. UCI Machine Learning Repository. DOI: 10.24432/C59K5F. [2] Breiman, L. (2001). Random Forests. Machine Learning, 45, 5-32. DOI: 10.1023/A:1010933404324. [3] Cortes, C., Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273-297. DOI: 10.1007/BF00994018. [4] Zhen, L., Chen, B., Wang, L., Yang, L., Xu, W., Huang, R.-J. (2025). Data imbalance causes underestimation of high ozone pollution in machine learning models: A weighted support vector regression solution. Atmospheric Environment, 343, 120952. DOI: 10.1016/j.atmosenv.2024.120952. [5] Hua, V., Nguyen, T., Dao, M.-S., Nguyen, H. D., Nguyen, B. T. (2024). The impact of data imputation on air quality prediction problem. PLOS ONE, 19(9), e0306303. DOI: 10.1371/journal.pone.0306303.